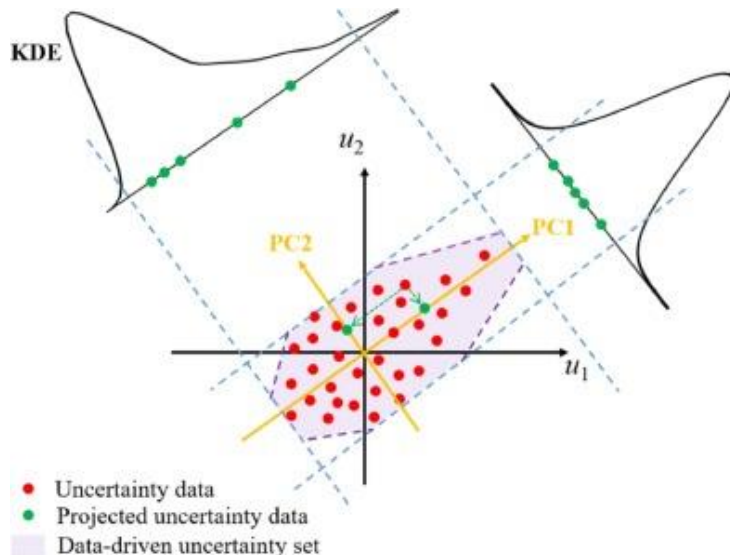


# Ενότητα Β' – Συστήματα Αβεβαιότητας 2\_Bayesian Συλλογιστική - Δίκτυα



Κατερίνα Γεωργούλη

Δεκέμβριος 2019

Bayesian Συλλογιστική

# Πιθανότητες: επανάληψη

- Conditional probability  $P(x|y) = \frac{P(x, y)}{P(y)}$
- Product rule  $P(x, y) = P(x|y)P(y)$
- Chain rule 
$$\begin{aligned} P(X_1, X_2, \dots, X_n) &= P(X_1)P(X_2|X_1)P(X_3|X_1, X_2) \dots \\ &= \prod_{i=1}^n P(X_i|X_1, \dots, X_{i-1}) \end{aligned}$$
- X, Y independent if and only if:  $\forall x, y : P(x, y) = P(x)P(y)$
- X and Y are conditionally independent given Z if and only if:

$$X \perp\!\!\!\perp Y | Z$$


$$\forall x, y, z : P(x, y|z) = P(x|z)P(y|z)$$

# Συλλογιστική λαμβάνοντας υπόψη Χρόνο και Χώρο

- Συχνά, θέλουμε **να εξάγουμε συμπεράσματα για μια σειρά** παρατηρήσεων
  - Αναγνώρισης ομιλίας
  - Εντοπισμός ρομπότ
  - Ιατρική παρακολούθηση
- Πρέπει να εισαγάγουμε χρόνο (ή χώρο) στα μοντέλα μας

# Μοντέλα Markov


- Η τιμή του  $X$  σε μια δεδομένη χρονική στιγμή ονομάζεται η **κατάσταση** (the **state**)



$$P(X_1) \quad P(X_t|X_{t-1})$$

- Παράμετροι: οι αποκαλούμενες πιθανότητες μετάβασης (**transition probabilities**) ή δυναμικές (dynamics), καθορίζουν τον τρόπο με τον οποίο εξελίσσεται η κατάσταση με την πάροδο του χρόνου (επίσης, πιθανότητες αρχικής κατάστασης)
- Υπόθεση ύπαρξης στασιμότητας: πιθανότητες μετάβασης οι ίδιες ανά πάσα χρονική στιγμή

# Κοινή Κατανομή του Μοντέλου Markov




- Κοινή κατανομή:

$$P(X_1, X_2, X_3, X_4) = P(X_1)P(X_2|X_1)P(X_3|X_2)P(X_4|X_3)$$

- Γενικότερα:

$$\begin{aligned} P(X_1, X_2, \dots, X_T) &= P(X_1)P(X_2|X_1)P(X_3|X_2) \dots P(X_T|X_{T-1}) \\ &= P(X_1) \prod_{t=2}^T P(X_t|X_{t-1}) \end{aligned}$$

# Αλυσιδωτός κανόνας και Μοντέλα Markov



- Από τον αλυσιδωτό κανόνα, κάθε κοινή κατανομή πάνω στο σύνολο  $X_1, X_2, X_3, X_4$  μπορεί να γραφεί ως:

$$P(X_1, X_2, X_3, X_4) = P(X_1)P(X_2|X_1)P(X_3|X_1, X_2)P(X_4|X_1, X_2, X_3)$$


- Υποθέτοντας ότι:

$$X_3 \perp\!\!\!\perp X_1 \mid X_2 \quad \text{and} \quad X_4 \perp\!\!\!\perp X_1, X_2 \mid X_3$$

Καταλήγουμε στη συνάρτηση της προηγούμενης διαφάνειας:

$$P(X_1, X_2, X_3, X_4) = P(X_1)P(X_2|X_1)P(X_3|X_2)P(X_4|X_3)$$

# Αλυσιδωτός κανόνας και Μοντέλα Markov



- Από τον αλυσιδωτό κανόνα, κάθε κοινή κατανομή πάνω στο σύνολο  $X_1, X_2, \dots, X_T$  μπορεί να γραφεί ως:

$$P(X_1, X_2, \dots, X_T) = P(X_1) \prod_{t=2}^T P(X_t | X_1, X_2, \dots, X_{t-1})$$

- Υποθέτοντας ότι για όλα τα  $t$ :


$$X_t \perp\!\!\!\perp X_1, \dots, X_{t-2} \mid X_{t-1}$$

καταλήγουμε στην έκφραση που δόθηκε στη προηγούμενη διαφάνεια:

$$P(X_1, X_2, \dots, X_T) = P(X_1) \prod_{t=2}^T P(X_t | X_{t-1})$$



# Υπονοούμενες υπό όρους ανεξαρτησίες



• Υποθέτουμε:  $X_3 \perp\!\!\!\perp X_1 \mid X_2$  and  $X_4 \perp\!\!\!\perp X_1, X_2 \mid X_3$

• Ισχύει ότι  $X_1 \perp\!\!\!\perp X_3, X_4 \mid X_2$  ?

Ναί!

Απόδειξη: 
$$\begin{aligned} P(X_1 \mid X_2, X_3, X_4) &= \frac{P(X_1, X_2, X_3, X_4)}{P(X_2, X_3, X_4)} \\ &= \frac{P(X_1)P(X_2 \mid X_1)P(X_3 \mid X_2)P(X_4 \mid X_3)}{\sum_{x_1} P(x_1)P(X_2 \mid x_1)P(X_3 \mid X_2)P(X_4 \mid X_3)} \\ &= \frac{P(X_1, X_2)}{P(X_2)} \\ &= P(X_1 \mid X_2) \end{aligned}$$

# Επανάληψη Μοντέλων Markov

- Σαφής παραδοχή για το  $t$ :  $X_t \perp\!\!\!\perp X_1, \dots, X_{t-2} \mid X_{t-1}$

- Επακόλουθο, η κοινή κατανομή μπορεί να γραφεί ως:

$$\begin{aligned} P(X_1, X_2, \dots, X_T) &= P(X_1)P(X_2|X_1)P(X_3|X_2) \dots P(X_T|X_{T-1}) \\ &= P(X_1) \prod_{t=2}^T P(X_t|X_{t-1}) \end{aligned}$$

- Υπονοούμενες υπο συνθήκες ανεξαρτησίες:

- Οι παλαιότερες μεταβλητές είναι ανεξάρτητες των μελλοντικών με δεδομένες τις παρούσες.

Π.χ., Εάν  $t_1 < t_2 < t_3$  ή  $t_1 > t_2 > t_3$  τότε:  $X_{t_1} \perp\!\!\!\perp X_{t_3} \mid X_{t_2}$

- Επιπλέον σαφείς παραδοχές:  $P(X_t \mid X_{t-1})$  είναι η ίδια για όλα τα  $t$ .

# Παράδειγμα Αλυσίδας Markov : Καιρός

- Καταστάσεις:



$$X = \{\text{rain}, \text{sun}\}$$

Δυο τρόποι αναπαράστασης του ίδιου CPT

- Αρχική κατανομή ( $t_0$ : 1.0 sun)

- CPT\*  $P(X_t | X_{t-1})$ :


$X_{t-1}$	$X_t$	$P(X_t   X_{t-1})$
sun	sun	0.9
sun	rain	0.1
rain	sun	0.3
rain	rain	0.7



\*Conditional Probability Table

# Παράδειγμα Αλυσίδας Markov : Καιρός

- Αρχική κατανομή: 1.0 sun




- Ποια είναι η πιθανοτική κατανομή μετά από ένα βήμα;

$$P(X_2 = \text{sun}) = P(X_2 = \text{sun} | X_1 = \text{sun})P(X_1 = \text{sun}) + P(X_2 = \text{sun} | X_1 = \text{rain})P(X_1 = \text{rain})$$

$$0.9 \cdot 1.0 + 0.3 \cdot 0.0 = 0.9$$

# Mini-Forward Αλγόριθμος

- Ερώτηση: Ποια είναι η  $P(X)$  σε κάποια μέρα  $t$ ?



$$P(x_1) = \text{known}$$

$$\begin{aligned} P(x_t) &= \sum_{x_{t-1}} P(x_{t-1}, x_t) \\ &= \sum_{x_{t-1}} P(x_t | x_{t-1}) P(x_{t-1}) \end{aligned}$$

*Forward simulation*

# Παραδειγματική εκτέλεση του Mini-Forward Αλγόριθμου

- Από την αρχική παρατήρηση για την παράμετρο sun:

$$\begin{array}{ccccc} \left\langle \begin{array}{c} 1.0 \\ 0.0 \end{array} \right\rangle & \left\langle \begin{array}{c} 0.9 \\ 0.1 \end{array} \right\rangle & \left\langle \begin{array}{c} 0.84 \\ 0.16 \end{array} \right\rangle & \left\langle \begin{array}{c} 0.804 \\ 0.196 \end{array} \right\rangle & \longrightarrow & \left\langle \begin{array}{c} 0.75 \\ 0.25 \end{array} \right\rangle \\ P(X_1) & P(X_2) & P(X_3) & P(X_4) & & P(X_\infty) \end{array}$$

- Από την αρχική παρατήρηση για την παράμετρο rain:

$$\begin{array}{ccccc} \left\langle \begin{array}{c} 0.0 \\ 1.0 \end{array} \right\rangle & \left\langle \begin{array}{c} 0.3 \\ 0.7 \end{array} \right\rangle & \left\langle \begin{array}{c} 0.48 \\ 0.52 \end{array} \right\rangle & \left\langle \begin{array}{c} 0.588 \\ 0.412 \end{array} \right\rangle & \longrightarrow & \left\langle \begin{array}{c} 0.75 \\ 0.25 \end{array} \right\rangle \\ P(X_1) & P(X_2) & P(X_3) & P(X_4) & & P(X_\infty) \end{array}$$

- Από την αρχική παρατήρηση για κάποια παράμετρο  $P(X_1)$ :

$$\begin{array}{ccc} \left\langle \begin{array}{c} p \\ 1-p \end{array} \right\rangle & \dots & \longrightarrow \left\langle \begin{array}{c} 0.75 \\ 0.25 \end{array} \right\rangle \\ P(X_1) & & P(X_\infty) \end{array}$$

# Σταθερές Κατανομές

- Για τις περισσότερες αλυσίδες ισχύει ότι:

- Η επίδραση της αρχικής κατανομής γίνεται ολοένα και λιγότερο σημαντική με την πάροδο του χρόνου.
- Η κατανομή στην οποία καταλήγουμε είναι ανεξάρτητη από την αρχική κατανομή


- Σταθερή Κατανομή:

- Στην κατανομή που καταλήγει η αλυσίδα καλείται **Σταθερή Κατανομή**  $P_\infty$  της αλυσίδας
- και ικανοποιεί τη σχέση:

$$P_\infty(X) = P_{\infty+1}(X) = \sum_x P(X|x)P_\infty(x)$$

# Παράδειγμα: Σταθερές Κατανομές

- Ερώτηση: Ποια είναι η  $P(X)$  την χρονική στιγμή  $t = \infty$ ;



$$P_{\infty}(\text{sun}) = P(\text{sun}|\text{sun})P_{\infty}(\text{sun}) + P(\text{sun}|\text{rain})P_{\infty}(\text{rain})$$

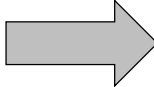
$$P_{\infty}(\text{rain}) = P(\text{rain}|\text{sun})P_{\infty}(\text{sun}) + P(\text{rain}|\text{rain})P_{\infty}(\text{rain})$$

$$P_{\infty}(\text{sun}) = 0.9P_{\infty}(\text{sun}) + 0.3P_{\infty}(\text{rain})$$

$$P_{\infty}(\text{rain}) = 0.1P_{\infty}(\text{sun}) + 0.7P_{\infty}(\text{rain})$$

$$P_{\infty}(\text{sun}) = 3P_{\infty}(\text{rain})$$

$$P_{\infty}(\text{rain}) = 1/3P_{\infty}(\text{sun})$$

Επίσης:  $P_{\infty}(\text{sun}) + P_{\infty}(\text{rain}) = 1$  

$$P_{\infty}(\text{sun}) = 3/4$$
$$P_{\infty}(\text{rain}) = 1/4$$

$X_{t-1}$	$X_t$	$P(X_t X_{t-1})$
sun	sun	0.9
sun	rain	0.1
rain	sun	0.3
rain	rain	0.7



# Κανόνας Bayes

- Δύο τρόποι για τον προσδιορισμό μιας κοινής κατανομής σε δύο εξαρτώμενες μεταβλητές:

$$P(x, y) = P(x|y)P(y) = P(y|x)P(x)$$

- Διαχωρίζοντας, παίρνουμε:

$$P(x|y) = \frac{P(y|x)}{P(y)}P(x)$$

- Γιατί είναι αυτό χρήσιμο;
  - Μας επιτρέπει να χτίσουμε μια πιθανότητα από την αντίστροφή της
  - Συχνά μια υπό συνθήκες κατανομή είναι δύσκολη αλλά η αντίστροφή της είναι απλή

That's my rule!



# Δίκτυα Bayes - Bayes' Nets

Δύο προβλήματα υπάρχουν με τη χρήση πινάκων πλήρως διασυνδεδεμένης κατανομής ως πιθανοτικά μοντέλα:

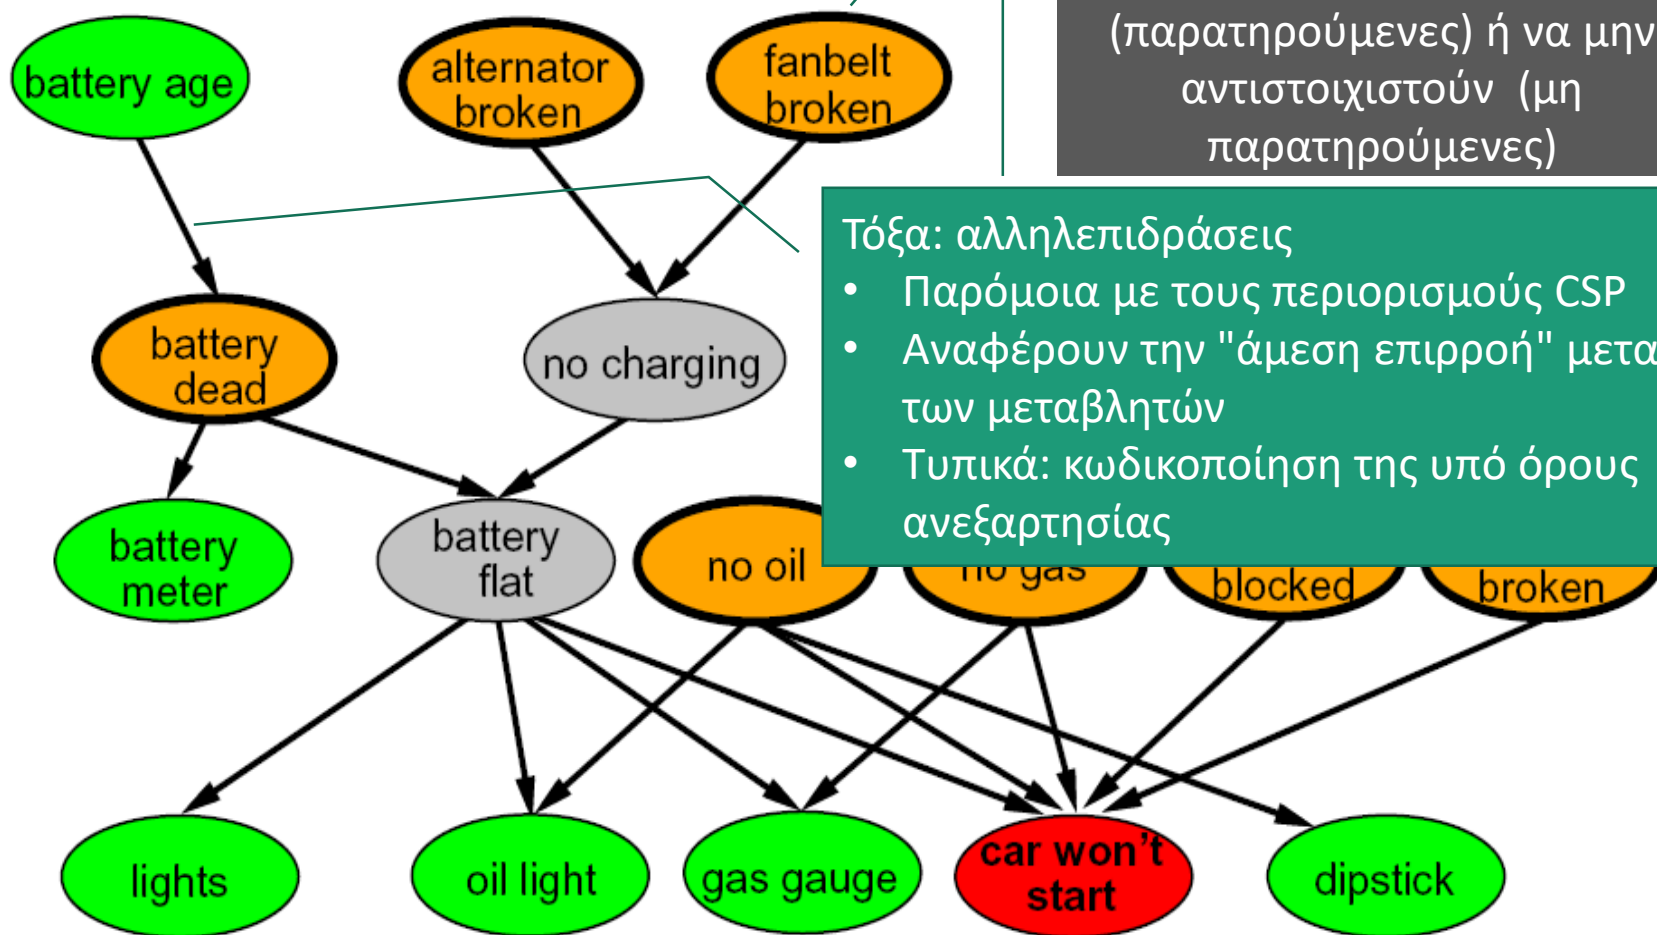
- Η διάρθρωση είναι πολύ μεγάλη ώστε να εκπροσωπείται ρητά, εκτός και αν υπάρχουν λίγες μεταβλητές
- Είναι δύσκολο να μάθεις (εκτιμήσεις) οτιδήποτε εμπειρικά για περισσότερες από μερικές μεταβλητές τη φορά

# Δίκτυα Bayes - Bayes' Nets

**Bayes' nets:** μια τεχνική για την περιγραφή πολύπλοκων κοινών κατανομών (μοντέλων) χρησιμοποιώντας απλές, τοπικές κατανομές (πιθανότητες υπό προϋποθέσεις - conditional probabilities)

- Πιο σωστά ονομάζονται γραφικά μοντέλα (**graphical models**)
- Περιγράφουν πώς αλληλεπιδρούν τοπικά οι μεταβλητές
- Τοπική αλυσίδα αλληλεπιδράσεων μαζί για να δώσει σφαιρικές, έμμεσες αλληλεπιδράσεις

# Παράδειγμα Bayes' Net: Αυτοκίνητο



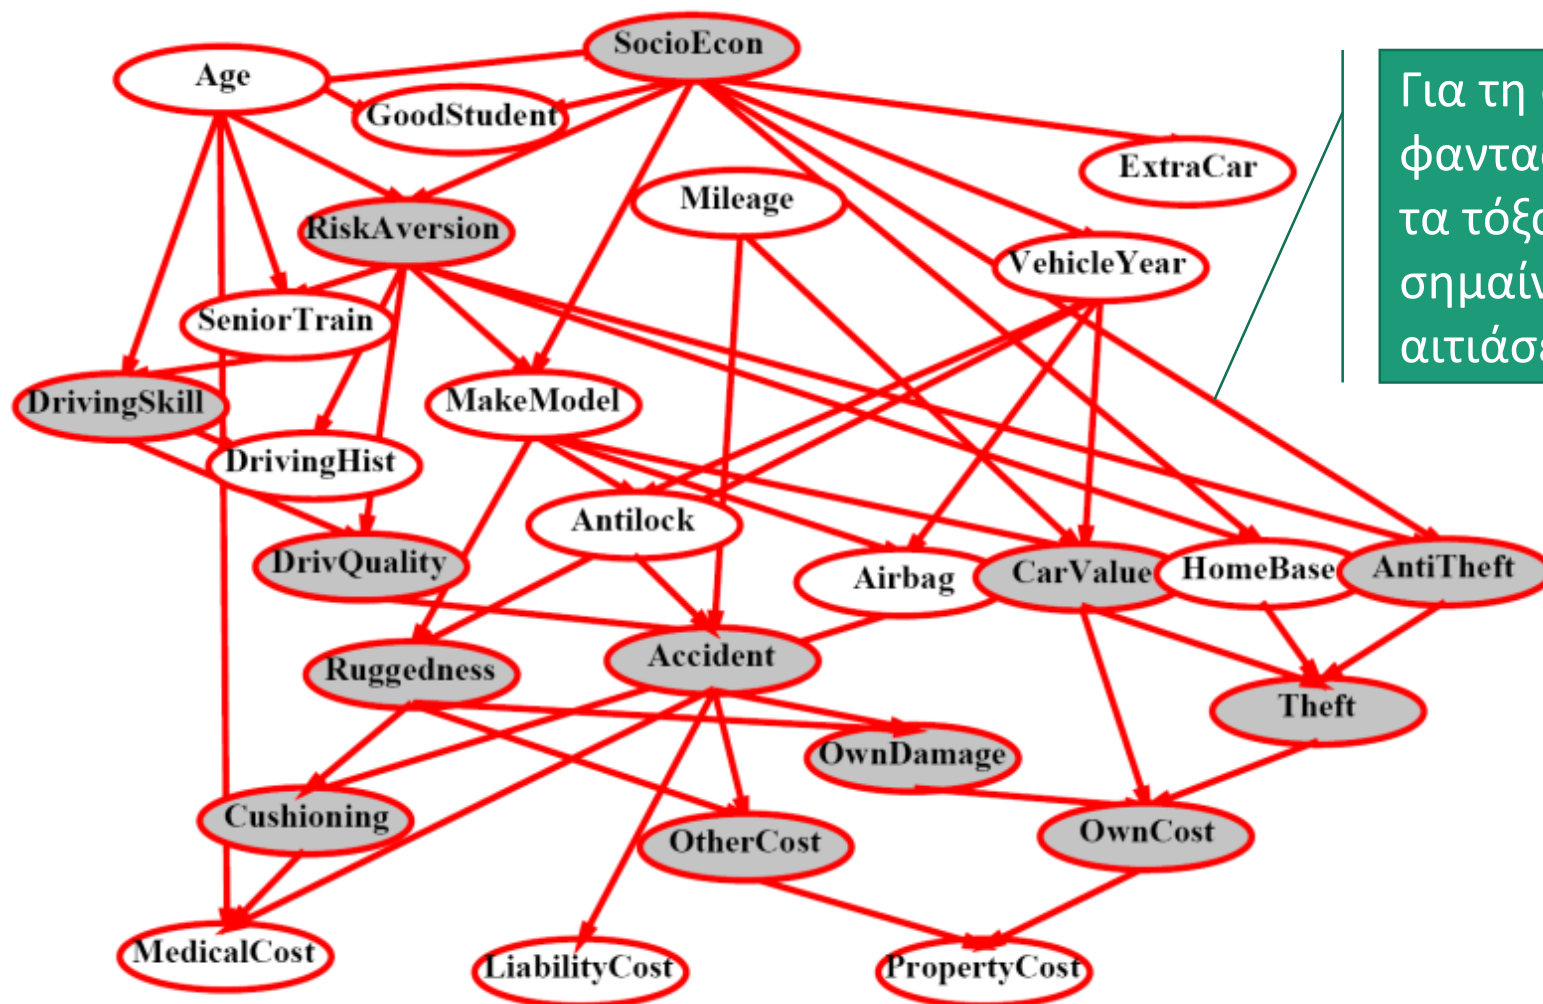
Κόμβοι: μεταβλητές (με τομείς)

Μπορεί να αντιστοιχιστούν (παρατηρούμενες) ή να μην αντιστοιχιστούν (μη παρατηρούμενες)

Τόξα: αλληλεπιδράσεις

- Παρόμοια με τους περιορισμούς CSP
- Αναφέρουν την "άμεση επιρροή" μεταξύ των μεταβλητών
- Τυπικά: κωδικοποίηση της υπό όρους ανεξαρτησίας



# Παράδειγμα Bayes' Net: Ασφάλεια




Για τη ώρα:  
φανταστείτε ότι  
τα τόξα  
σημαίνουν άμεσες  
αιτιάσεις

# Παράδειγμα: Ρίξεις Νομίσματος

- $N$  ανεξάρτητες ρίψεις νομίσματος



...



- Όχι συσχετισμοί μεταξύ των μεταβλητών: **απόλυτη ανεξαρτησία**


# Παράδειγμα: Κυκλοφοριακή συμφόρηση

- Variables:
  - R: It rains
  - T: There is traffic

■ Μοντέλο 1: ανεξαρτησία



■ Μοντέλο 2: εξάρτηση-η βροχή προκαλεί συμφόρηση



# Άσκηση: Κυκλοφοριακή συμφόρηση II

Φτιάξτε ένα γραφικό μοντέλο για την αλληλεξάρτηση των μεταβλητών:

- T: Συμφόρηση
- R: Βρέχει
- V: Ορατότητα
- A: Ατύχημα
- S: Οδόστρωμα
- C: Κλειστοί δρόμοι





# Τα Semantics των Bayes' Δικτύων

- Ένα σύνολο κόμβων, ένας για κάθε μεταβλητή  $X$
- Ένας κατευθυνόμενος, άκυκλος γράφος (που συνθέτουν οι ακμές)


- Μια κατανομή υπό συνθήκη για κάθε κόμβο

- Μια συλλογή από κατανομές επί του  $X$ ,

$$P(X|a_1 \dots a_n)$$

- Ένας CPT: πίνακας υπό συνθήκη πιθανότητας (conditional probability table)

- Περιγραφή μιας θορυβώδους (noisy) «αιτιώδους» διαδικασίας



*A Bayes net = Topology (graph) + Local Conditional Probabilities*

# Πιθανότητες στα BNs


- Τα Bayes' nets **κωδικοποιούν εμμέσως τις κοινές κατανομές**
  - Ως αποτέλεσμα των τοπικών υπό συνθήκες κατανομών

$$P(x_1, x_2, \dots, x_n) = \prod_{i=1}^n P(x_i | \text{parents}(X_i))$$

- Για να βρεθεί η πιθανότητα που δίνει ένα BN με πλήρη ανάθεση τιμών στους κόμβους του, αρκεί να πολλαπλασιαστούν μαζί όλες οι σχετικές συνθήκες :

- Παράδειγμα:


$$P(+cavity, +catch, -toothache)$$



# Πιθανότητες στα BNs

## Παράδειγμα 2

$$\begin{aligned} & \mathbf{P}(j \wedge m \wedge a \wedge \neg b \wedge \neg e) \\ &= \mathbf{P}(j \mid a) \mathbf{P}(m \mid a) \mathbf{P}(a \mid \neg b, \neg e) \mathbf{P}(\neg b) \mathbf{P}(\neg e) \end{aligned}$$



# Πιθανότητες σε BNs

- Ο αλυσιδωτός κανόνας (ισχύει για όλες τις κατανομές):

$$P(x_1, x_2, \dots, x_n) = \prod_{i=1}^n P(x_i | x_1 \dots x_{i-1})$$

- Υποθέτουμε τις υπό συνθήκες ανεξαρτησίες :


$$P(x_i | x_1, \dots, x_{i-1}) = P(x_i | \text{parents}(X_i))$$

→ Μπορούμε να συμπεράνουμε ότι:

$$P(x_1, x_2, \dots, x_n) = \prod_{i=1}^n P(x_i | \text{parents}(X_i))$$

- Δεν είναι δυνατόν κάθε BN να μπορεί να αναπαραστήσει κάθε κοινή κατανομή
  - Η τοπολογία επιβάλλει κάποιες υπό συνθήκες ανεξαρτησίες


# Παράδειγμα: Ρίψεις Νομίσματος



$$P(h, h, t, h) =$$

*Μόνο κατανομές με ανεξάρτητες μεταβλητές μπορούν να αναπαρασταθούν με Bayes' net χωρίς τόξα.*

# Παράδειγμα: Κυκλοφοριακή συμφόρηση



$P(R)$

$+r$	$1/4$
$-r$	$3/4$

$P(T|R)$

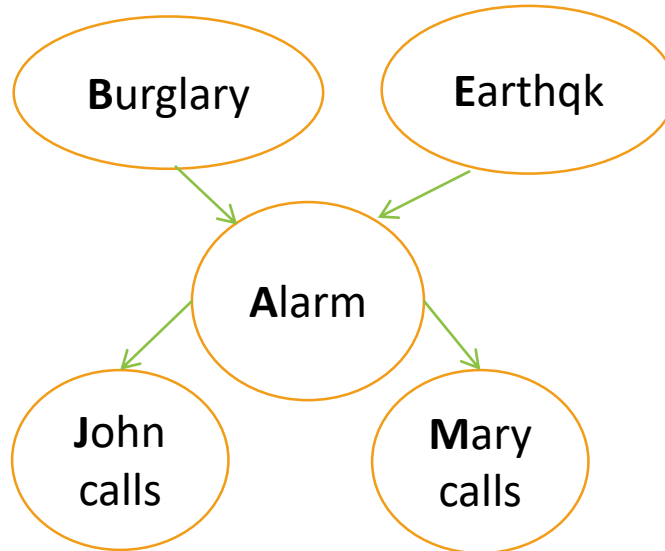
$+r$	$+t$	$3/4$
	$-t$	$1/4$

$-r$	$+t$	$1/2$
	$-t$	$1/2$


$$P(+r, -t) =$$

# Παράδειγμα: Συναγερμός

B	P(B)
+b	0.001
-b	0.999



E	P(E)
+e	0.002
-e	0.998


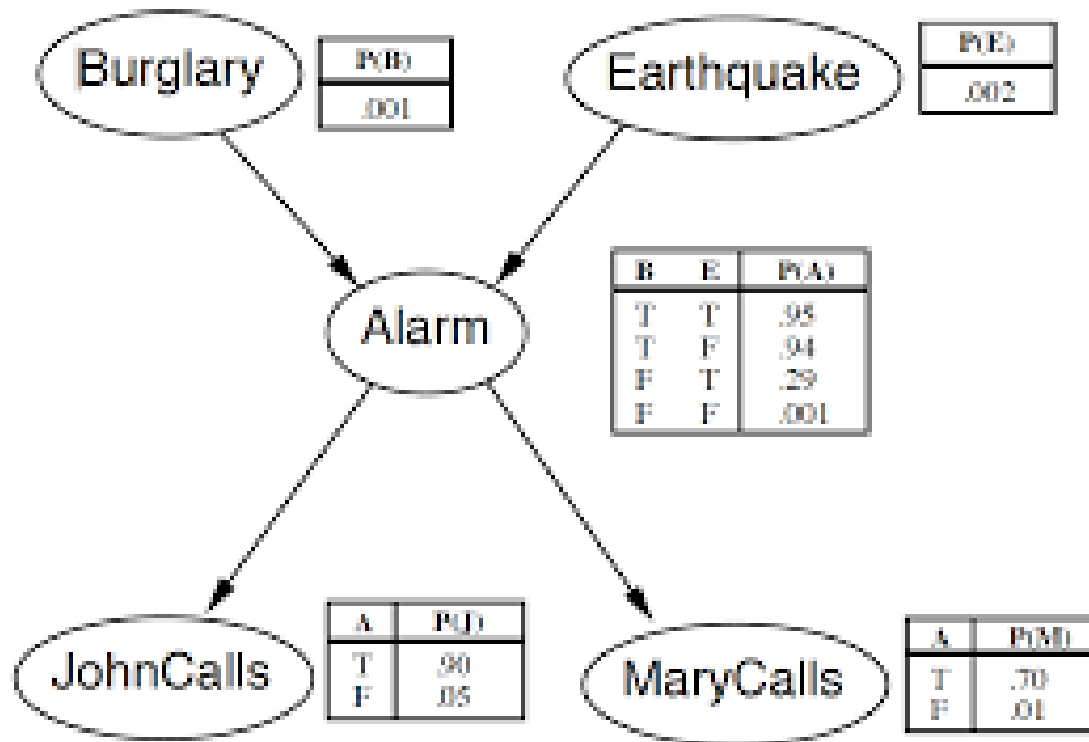


A	J	P(J A)
+a	+j	0.9
+a	-j	0.1
-a	+j	0.05
-a	-j	0.95

A	M	P(M A)
+a	+m	0.7
+a	-m	0.3
-a	+m	0.01
-a	-m	0.99

B	E	A	P(A B,E)
+b	+e	+a	0.95
+b	+e	-a	0.05
+b	-e	+a	0.94
+b	-e	-a	0.06
-b	+e	+a	0.29
-b	+e	-a	0.71
-b	-e	+a	0.001
-b	-e	-a	0.999


# Παράδειγμα: Συναγερμός (άλλη αναπαράσταση)





# Παράδειγμα: Κυκλοφοριακή συμφόρηση

- Αιτιώδης κατεύθυνση (Causal direction)



$P(R)$

$+r$	$1/4$
$-r$	$3/4$

$P(T|R)$

$+r$	$+t$	$3/4$
	$-t$	$1/4$


$-r$	$+t$	$1/2$
	$-t$	$1/2$

$P(T, R)$

$+r$	$+t$	$3/16$
$+r$	$-t$	$1/16$
$-r$	$+t$	$6/16$
$-r$	$-t$	$6/16$

# Παράδειγμα: Αντίστροφη Κυκλοφοριακή Συμφόρηση

- Τι θα γίνει αν αντιστρέψουμε την αιτιώδη κατεύθυνση?



$P(T)$

+t	9/16
-t	7/16

$P(R|T)$

+t	+r	1/3
	-r	2/3

-t	+r	1/7
	-r	6/7

$P(T, R)$

+r	+t	3/16
+r	-t	1/16
-r	+t	6/16
-r	-t	6/16

# Αλυσίδες Αιτίου-Αιτιατού

- Το παρακάτω αποτελεί μια “αιτιώδη αλυσίδα (causal chain)”



- Δυο απομακρυσμένες μεταβλητές της αλυσίδας ΔΕΝ ΕΙΝΑΙ απαραίτητα ανεξάρτητες.

- Για παράδειγμα:

$$P(+y \mid +x) = 1, P(-y \mid -x) = 1,$$

$$P(+z \mid +y) = 1, P(-z \mid -y) = 1$$

$$P(x, y, z) = P(x)P(y|x)P(z|y)$$

# Αλυσίδες Αιτίου-Αιτιατού

- Το παρακάτω αποτελεί μια “αιτιώδη αλυσίδα (causal chain)”



$$P(x, y, z) = P(x)P(y|x)P(z|y)$$

- Δυο απομακρυσμένες μεταβλητές της αλυσίδας ΕΙΝΑΙ ανεξάρτητες δεδομένων των ενδιάμεσων μεταβλητών.

- Για παράδειγμα:

$$P(z|x, y) = \frac{P(x, y, z)}{P(x, y)}$$

$$= \frac{P(x)P(y|x)P(z|y)}{P(x)P(y|x)}$$

$$= P(z|y)$$

# Κατασκευή Bayesian δικτύων

$n$

$n$

1. Επέλεξε ένα σύνολο μεταβλητών  $X_1, \dots, X_n$
2. Από  $i = 1$  έως  $n$   
    πρόσθεσε  $X_i$  στο δίκτυο  
    Διάλεξε τους γονείς από το σύνολο  $X_1, \dots, X_{i-1}$  τέτοιους που
$$\mathbf{P}(X_i / \text{Parents}(X_i)) = \mathbf{P}(X_i / X_1, \dots, X_{i-1})$$

Μια τέτοια επιλογή γονέων εγγυάται ότι:

$$\begin{aligned}\mathbf{P}(X_1, \dots, X_n) &= \prod_{i=1}^n \mathbf{P}(X_i / X_1, \dots, X_{i-1}) \text{ (chain rule)} \\ &= \prod_{i=1}^n \mathbf{P}(X_i / \text{Parents}(X_i)) \text{ (εκ της κατασκευής)}\end{aligned}$$

# Παράδειγμα κατασκευής BN

Έστω ότι επιλέγουμε τη σειρά των μεταβλητών  
*M, J, A, B, E* για το παράδειγμα του συναγερμού

MaryCalls


JohnCalls

Ισχύει ότι

$$P(J \mid M) = P(J)?$$

# Παράδειγμα κατασκευής BN

Έστω ότι επιλέγουμε τη σειρά των μεταβλητών  
*M, J, A, B, E* για το παράδειγμα του συναγερμού




Ισχύει ότι

$P(J \mid M) = P(J)$ ? **No**

$P(A \mid J, M) = P(A \mid J)$ ?  $P(A \mid J, M) = P(A)$ ?

# Παράδειγμα κατασκευής BN

Έστω ότι επιλέγουμε τη σειρά των μεταβλητών  
 $M, J, A, B, E$  για το παράδειγμα του συναγερμού



Ισχύει ότι

$P(J \mid M) = P(J)$ ? **No**

$P(A \mid J, M) = P(A \mid J)$ ?  $P(A \mid J, M) = P(A)$ ? **No**


$P(B \mid A, J, M) = P(B \mid A)$ ?

$P(B \mid A, J, M) = P(B)$ ?



# Παράδειγμα κατασκευής BN

Έστω ότι επιλέγουμε τη σειρά των μεταβλητών  
 $M, J, A, B, E$  για το παράδειγμα του συναγερμού



Ισχύει ότι

$P(J \mid M) = P(J)$ ? **No**

$P(A \mid J, M) = P(A \mid J)$ ?  $P(A \mid J, M) = P(A)$ ? **No**

$P(B \mid A, J, M) = P(B \mid A)$ ? **Yes**

$P(B \mid A, J, M) = P(B)$ ? **No**

$P(E \mid B, A, J, M) = P(E \mid A)$ ?

$P(E \mid B, A, J, M) = P(E \mid A, B)$ ?

# Παράδειγμα κατασκευής BN

Έστω ότι επιλέγουμε τη σειρά των μεταβλητών  
 $M, J, A, B, E$  για το παράδειγμα του συναγερμού

Ισχύει ότι

$P(J \mid M) = P(J)$ ? **No**


$P(A \mid J, M) = P(A \mid J)$ ?  $P(A \mid J, M) = P(A)$ ? **No**

$P(B \mid A, J, M) = P(B \mid A)$ ? **Yes**

$P(B \mid A, J, M) = P(B)$ ? **No**

$P(E \mid B, A, J, M) = P(E \mid A)$ ? **No**

$P(E \mid B, A, J, M) = P(E \mid A, B)$ ? **Yes**



# Άσκηση: Συναγερμός

Φτιάξτε BN για την αλληλεξάρτηση των παρακάτω μεταβλητών και τους αντίστοιχους πίνακες πιθανοτήτων και αλληλεξαρτήσεων και αναφέρετε ρητά τις αλυσίδες αιτίου-αιτιατού και τις ανεξάρτητες μεταξύ τους μεταβλητές :

C: Εκδήλωση καρκίνου

A: Ηλικία

G: Φύλλο

E: Έκθεση σε τοξικά

S: Κάπνισμα

L: Καρκίνος του πνεύμονα

T: Χημειοθεραπεία

# Δίκτυα Απόφασης

- Επιλογή ενέργειας που μεγιστοποιεί την προσδοκώμενη ωφέλεια ( $u$ ) βάσει των ισχυρισμών

- Νέοι τύποι κόμβων:



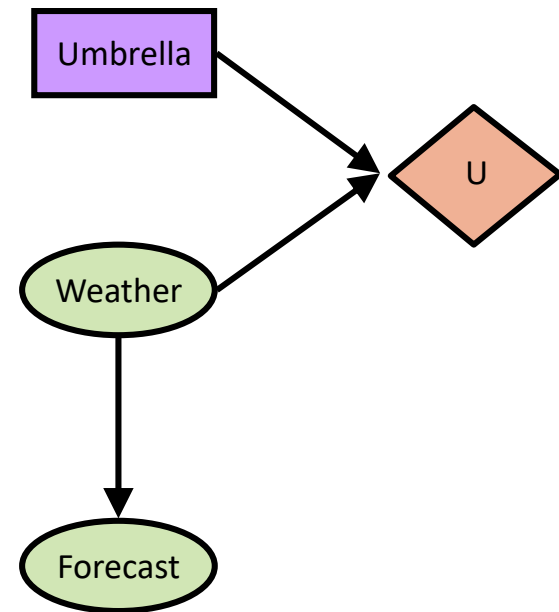
- Κόμβοι πιθανότητας (ακριβώς όπως στα BNs)



- Ενέργειες (ορθογώνια, δεν μπορούν να έχουν γονείς, ενεργούν ως παρατηρούμενα στοιχεία)



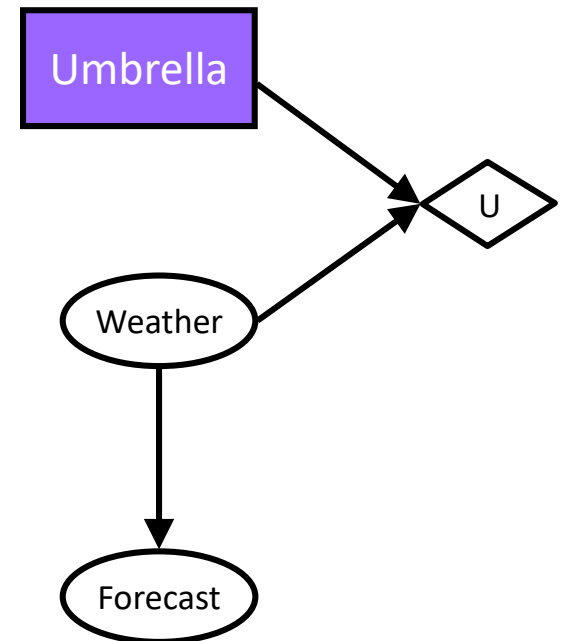
- Κόμβος χρησιμότητας (ρόμβος, εξαρτάται από κόμβους δράσης και πιθανότητας)



# Δίκτυα Απόφασης

## ■ Επιλογή Ενέργειας


- Υποθέστε όλους τους ισχυρισμούς για το πρόβλημα (καιρός)
- Θέστε τους κόμβους ενεργειών με κάθε αρμόζοντα τρόπο (να πάρω-να μη πάρω ομπρέλα)
- Υπολογίστε τα προγενέστερα για όλους τους γονείς του κόμβου χρησιμότητας, δεδομένων των ισχυρισμών που υποθέσατε (πρόγνωση)
- Υπολογίστε την αναμενόμενη χρησιμότητα για κάθε κόμβο ενέργειας
- Επιλέξτε την ενέργεια που μεγιστοποιεί το αποτέλεσμα



# Δίκτυα Απόφασης

Umbrella = leave

$$\begin{aligned} EU(\text{leave}) &= \sum_w P(w)U(\text{leave}, w) \\ &= 0.7 \cdot 100 + 0.3 \cdot 0 = 70 \end{aligned}$$



Umbrella = take

$$\begin{aligned} EU(\text{take}) &= \sum_w P(w)U(\text{take}, w) \\ &= 0.7 \cdot 20 + 0.3 \cdot 70 = 35 \end{aligned}$$

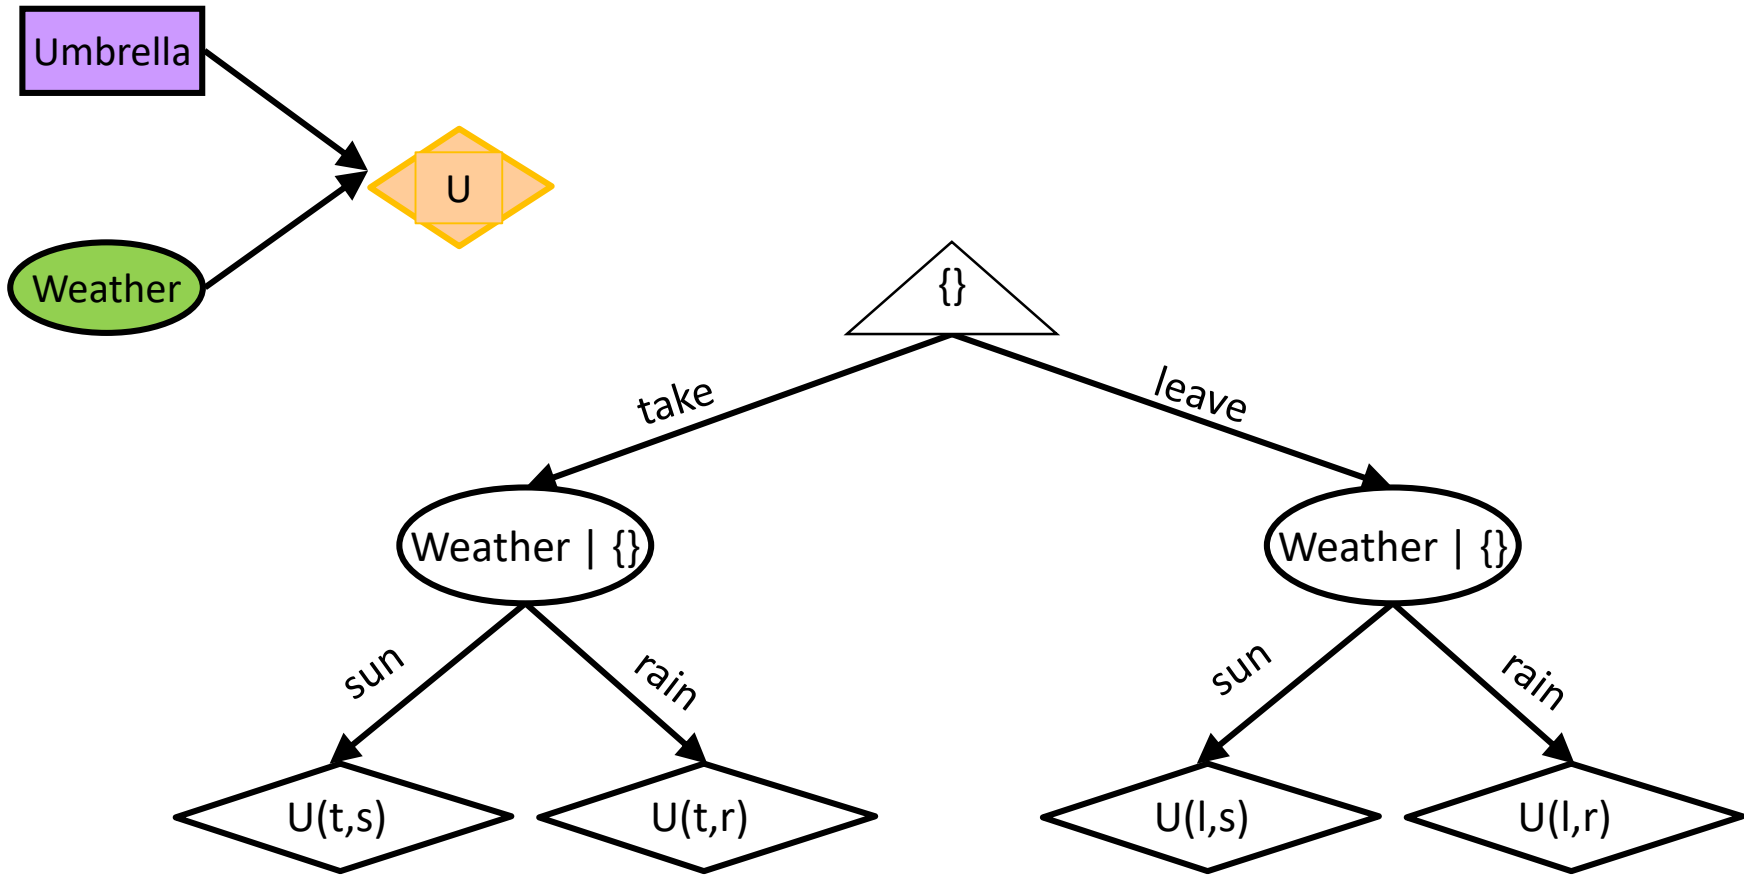
W	P(W)
sun	0.7
rain	0.3

Optimal decision = leave

$$MEU(\emptyset) = \max_a EU(a) = 70$$

A	W	U(A,W)
leave	sun	100
leave	rain	0
take	sun	20
take	rain	70

# Οι Αποφάσεις ως Δένδρα



# Παράδειγμα: Δίκτυα Απόφασης

Umbrella = leave

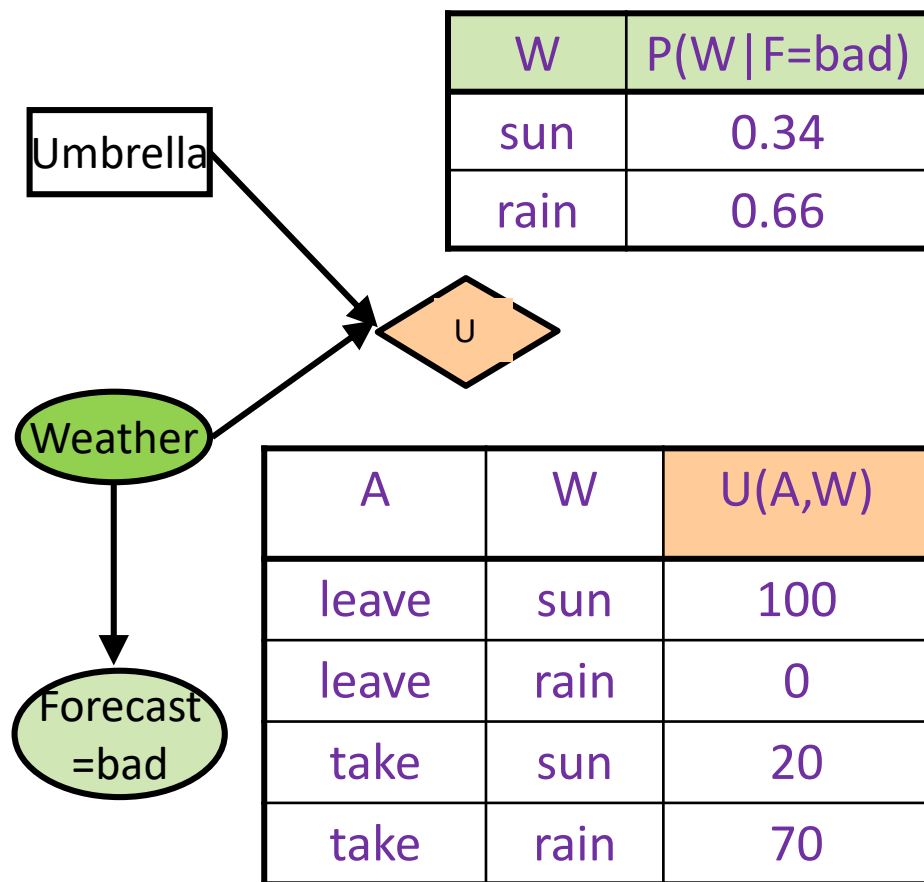
$$\begin{aligned} EU(\text{leave}|\text{bad}) &= \sum_w P(w|\text{bad})U(\text{leave}, w) \\ &= 0.34 \cdot 100 + 0.66 \cdot 0 = 34 \end{aligned}$$

Umbrella = take

$$\begin{aligned} EU(\text{take}|\text{bad}) &= \sum_w P(w|\text{bad})U(\text{take}, w) \\ &= 0.34 \cdot 20 + 0.66 \cdot 70 = 53 \end{aligned}$$

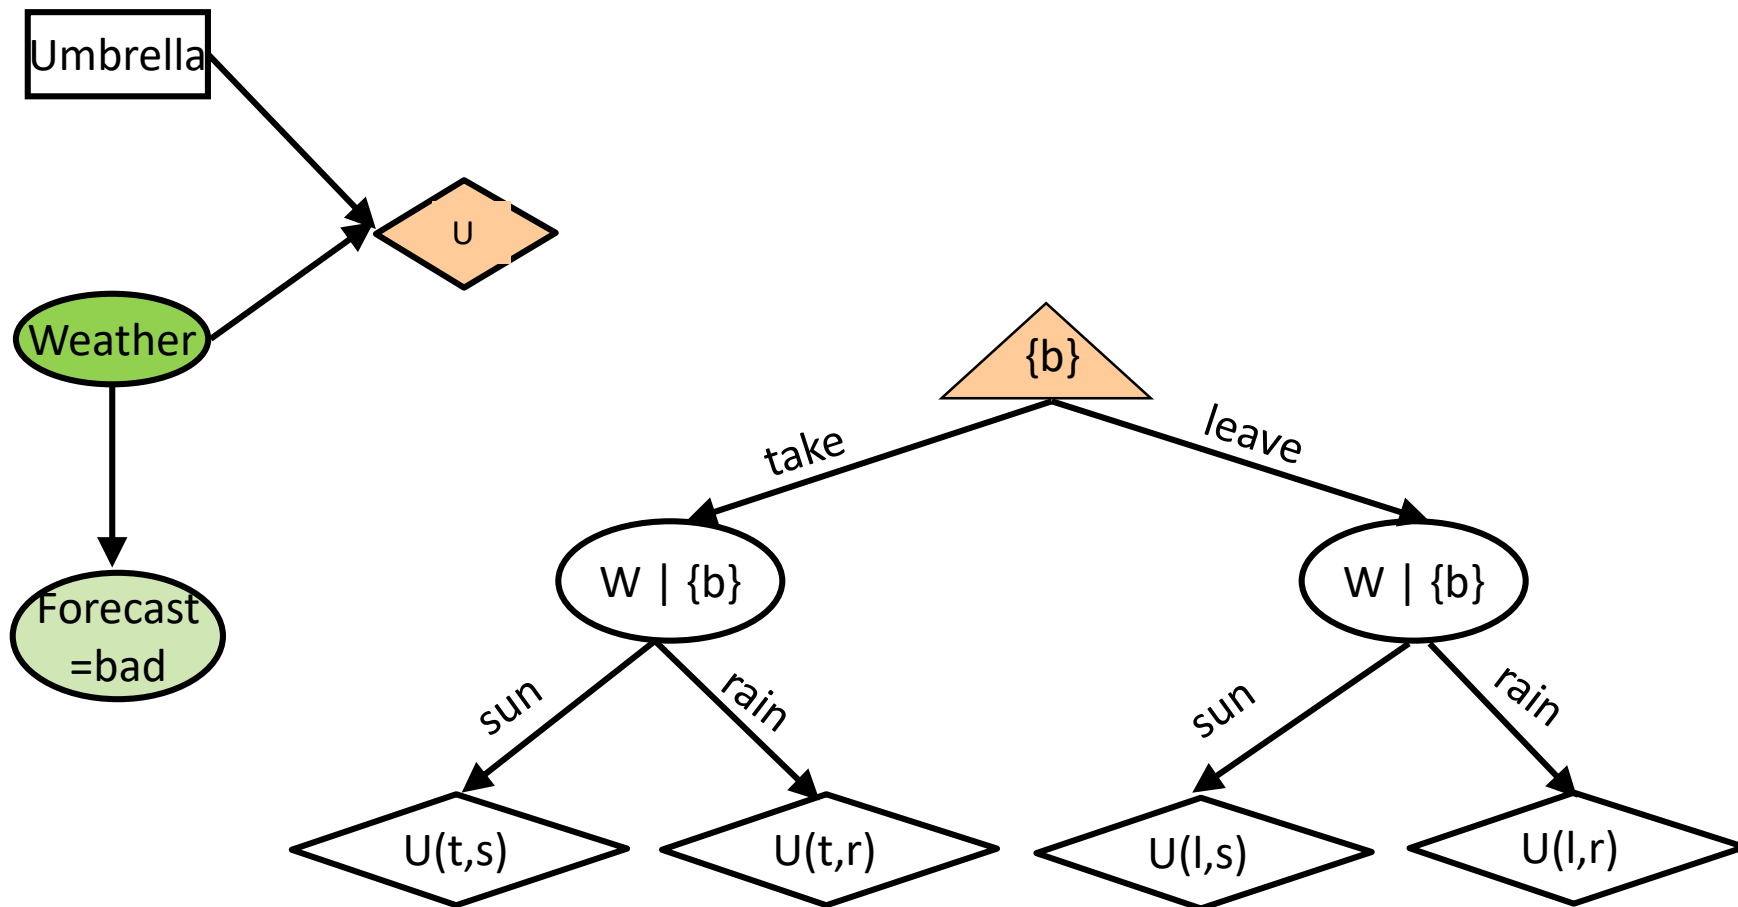
Optimal decision = take

$$MEU(F = \text{bad}) = \max_a EU(a|\text{bad}) = 53$$





# Αποφάσεις ως Δένδρα



Τέλος Ενότητας