


## Ενότητα Β' – Συστήματα Αβεβαιότητας 2\_Bayesian Συλλογιστική - Δίκτυα

## Bayesian Συλλογιστική



Κατερίνα Γεωργούλη  
Δεκέμβριος 2019

### Πιθανότητες: επανάληψη

- **Conditional probability**  $P(x|y) = \frac{P(x,y)}{P(y)}$
- **Product rule**  $P(x,y) = P(x|y)P(y)$
- **Chain rule**  $P(X_1, X_2, \dots, X_n) = P(X_1)P(X_2|X_1)P(X_3|X_1, X_2) \dots$   
 $= \prod_{i=1}^n P(X_i|X_1, \dots, X_{i-1})$
- **X, Y independent if and only if:**  $\forall x, y : P(x,y) = P(x)P(y)$
- **X and Y are conditionally independent given Z if and only if:**


$$X \perp\!\!\!\perp Y|Z \quad \forall x, y, z : P(x,y|z) = P(x|z)P(y|z)$$

### Συλλογιστική λαμβάνοντας υπόψη Χρόνο και Χώρο

- Συχνά, θέλουμε να εξάγουμε συμπεράσματα για μια σειρά παρατηρήσεων
  - Αναγνώρισης ομιλίας
  - Εντοπισμός ρομπότ
  - Ιατρική παρακολούθηση
- Πρέπει να εισαγάγουμε χρόνο (ή χώρο) στα μοντέλα μας


## Μοντέλα Markov

- Η τιμή του  $X$  σε μια δεδομένη χρονική στιγμή ονομάζεται η **κατάσταση** (the **state**)



- Παράμετροι: οι αποκαλούμενες πιθανότητες μετάβασης (**transition probabilities**) ή δυναμικές (dynamics), καθορίζουν τον τρόπο με τον οποίο εξελίσσεται η κατάσταση με την πάροδο του χρόνου (επίσης, πιθανότητες αρχικής κατάστασης)
- Υπόθεση ύπαρξης στασιμότητας: πιθανότητες μετάβασης οι ίδιες ανά πάσα χρονική στιγμή

## Αλυσιδωτός κανόνας και Μοντέλα Markov



- Από τον αλυσιδωτό κανόνα, κάθε κοινή κατανομή πάνω στο σύνολο  $X_1, X_2, X_3, X_4$  μπορεί να γραφεί ως:

$$P(X_1, X_2, X_3, X_4) = P(X_1)P(X_2|X_1)P(X_3|X_1, X_2)P(X_4|X_1, X_2, X_3)$$


- Υποθέτοντας ότι:

$$X_3 \perp\!\!\!\perp X_1 \mid X_2 \quad \text{and} \quad X_4 \perp\!\!\!\perp X_1, X_2 \mid X_3$$

Καταλήγουμε στη συνάρτηση της προηγούμενης διαφάνειας:

$$P(X_1, X_2, X_3, X_4) = P(X_1)P(X_2|X_1)P(X_3|X_2)P(X_4|X_3)$$

## Κοινή Κατανομή του Μοντέλου Markov




- Κοινή κατανομή:

$$P(X_1, X_2, X_3, X_4) = P(X_1)P(X_2|X_1)P(X_3|X_2)P(X_4|X_3)$$

- Γενικότερα:

$$\begin{aligned} P(X_1, X_2, \dots, X_T) &= P(X_1)P(X_2|X_1)P(X_3|X_2) \dots P(X_T|X_{T-1}) \\ &= P(X_1) \prod_{t=2}^T P(X_t|X_{t-1}) \end{aligned}$$

## Αλυσιδωτός κανόνας και Μοντέλα Markov



- Από τον αλυσιδωτό κανόνα, κάθε κοινή κατανομή πάνω στο σύνολο  $X_1, X_2, \dots, X_T$  μπορεί να γραφεί ως:

$$P(X_1, X_2, \dots, X_T) = P(X_1) \prod_{t=2}^T P(X_t|X_1, X_2, \dots, X_{t-1})$$


- Υποθέτοντας ότι για όλα τα  $t$ :

$$X_t \perp\!\!\!\perp X_1, \dots, X_{t-2} \mid X_{t-1}$$

καταλήγουμε στην έκφραση που δόθηκε στη προηγούμενη διαφάνεια:

$$P(X_1, X_2, \dots, X_T) = P(X_1) \prod_{t=2}^T P(X_t|X_{t-1})$$

## Υπονοούμενες υπό όρους ανεξαρτησίες



• Υποθέτουμε:  $X_3 \perp\!\!\!\perp X_1 \mid X_2$  and  $X_4 \perp\!\!\!\perp X_1, X_2 \mid X_3$

• Ισχύει ότι  $X_1 \perp\!\!\!\perp X_3, X_4 \mid X_2$  ?

Ναί!

Απόδειξη: 
$$P(X_1 \mid X_2, X_3, X_4) = \frac{P(X_1, X_2, X_3, X_4)}{P(X_2, X_3, X_4)}$$

$$= \frac{P(X_1)P(X_2 \mid X_1)P(X_3 \mid X_2)P(X_4 \mid X_3)}{\sum_{x_1} P(x_1)P(X_2 \mid x_1)P(X_3 \mid X_2)P(X_4 \mid X_3)}$$

$$= \frac{P(X_1, X_2)}{P(X_2)}$$

$$= P(X_1 \mid X_2)$$

## Επανάληψη Μοντέλων Markov

• Σαφής παραδοχή για το  $t$ :  $X_t \perp\!\!\!\perp X_1, \dots, X_{t-2} \mid X_{t-1}$

• Επακόλουθο, η κοινή κατανομή μπορεί να γραφεί ως:

$$P(X_1, X_2, \dots, X_T) = P(X_1)P(X_2 \mid X_1)P(X_3 \mid X_2) \dots P(X_T \mid X_{T-1})$$

$$= P(X_1) \prod_{t=2}^T P(X_t \mid X_{t-1})$$

• Υπονοούμενες υπο συνθήκες ανεξαρτησίες:

• Οι παλαιότερες μεταβλητές είναι ανεξάρτητες των μελλοντικών με δεδομένες τις παρούσες.

Π.χ., Εάν  $t_1 < t_2 < t_3$  ή  $t_1 > t_2 > t_3$  τότε:  $X_{t_1} \perp\!\!\!\perp X_{t_3} \mid X_{t_2}$

• Επιπλέον σαφείς παραδοχές:  $P(X_t \mid X_{t-1})$  είναι η ίδια για όλα τα  $t$ .

## Παράδειγμα Αλυσίδας Markov : Καιρός

■ Καταστάσεις:



$X = \{\text{rain}, \text{sun}\}$

Δυο τρόποι αναπαράστασης του ίδιου CPT

■ Αρχική κατανομή ( $t_0$ : 1.0 sun)


■ CPT\*  $P(X_t \mid X_{t-1})$ :

$X_{t-1}$	$X_t$	$P(X_t \mid X_{t-1})$
sun	sun	0.9
sun	rain	0.1
rain	sun	0.3
rain	rain	0.7



## Παράδειγμα Αλυσίδας Markov : Καιρός

• Αρχική κατανομή: 1.0 sun




• Ποια είναι η πιθανοτική κατανομή μετά από ένα βήμα;

$$P(X_2 = \text{sun}) = P(X_2 = \text{sun} \mid X_1 = \text{sun})P(X_1 = \text{sun}) + P(X_2 = \text{sun} \mid X_1 = \text{rain})P(X_1 = \text{rain})$$

$$0.9 \cdot 1.0 + 0.3 \cdot 0.0 = 0.9$$

# Mini-Forward Αλγόριθμος

- Ερώτηση: Ποια είναι η  $P(X)$  σε κάποια μέρα  $t$ ?



$$P(x_1) = \text{known}$$

$$P(x_t) = \sum_{x_{t-1}} P(x_{t-1}, x_t)$$

$$= \sum_{x_{t-1}} P(x_t | x_{t-1}) P(x_{t-1})$$

*Forward simulation*

## Παραδειγματική εκτέλεση του Mini-Forward Αλγορίθμου

- Από την αρχική παρατήρηση για την παράμετρο sun:

$$\begin{matrix} \langle 1.0 \\ 0.0 \rangle & \langle 0.9 \\ 0.1 \rangle & \langle 0.84 \\ 0.16 \rangle & \langle 0.804 \\ 0.196 \rangle & \Rightarrow \langle 0.75 \\ 0.25 \rangle \\ P(X_1) & P(X_2) & P(X_3) & P(X_4) & P(X_\infty) \end{matrix}$$

- Από την αρχική παρατήρηση για την παράμετρο rain:

$$\begin{matrix} \langle 0.0 \\ 1.0 \rangle & \langle 0.3 \\ 0.7 \rangle & \langle 0.48 \\ 0.52 \rangle & \langle 0.588 \\ 0.412 \rangle & \Rightarrow \langle 0.75 \\ 0.25 \rangle \\ P(X_1) & P(X_2) & P(X_3) & P(X_4) & P(X_\infty) \end{matrix}$$

- Από την αρχική παρατήρηση για κάποια παράμετρο  $P(X_1)$ :

$$\begin{matrix} \langle p \\ 1-p \rangle & \dots & \Rightarrow \langle 0.75 \\ 0.25 \rangle \\ P(X_1) & & P(X_\infty) \end{matrix}$$

## Σταθερές Κατανομές

- Για τις περισσότερες αλυσίδες ισχύει ότι:

- Η επίδραση της αρχικής κατανομής γίνεται ολοένα και λιγότερο σημαντική με την πάροδο του χρόνου.
- Η κατανομή στην οποία καταλήγουμε είναι ανεξάρτητη από την αρχική κατανομή


- **Σταθερή Κατανομή:**

- Στην κατανομή που καταλήγει η αλυσίδα καλείται **Σταθερή Κατανομή**  $P_\infty$  της αλυσίδας
- και ικανοποιεί τη σχέση:

$$P_\infty(X) = P_{\infty+1}(X) = \sum_x P(X|x) P_\infty(x)$$

## Παράδειγμα: Σταθερές Κατανομές

- Ερώτηση: Ποια είναι η  $P(X)$  την χρονική στιγμή  $t = \infty$ ;



$$P_\infty(\text{sun}) = P(\text{sun}|\text{sun})P_\infty(\text{sun}) + P(\text{sun}|\text{rain})P_\infty(\text{rain})$$

$$P_\infty(\text{rain}) = P(\text{rain}|\text{sun})P_\infty(\text{sun}) + P(\text{rain}|\text{rain})P_\infty(\text{rain})$$

$$P_\infty(\text{sun}) = 0.9P_\infty(\text{sun}) + 0.3P_\infty(\text{rain})$$

$$P_\infty(\text{rain}) = 0.1P_\infty(\text{sun}) + 0.7P_\infty(\text{rain})$$

$$P_\infty(\text{sun}) = 3P_\infty(\text{rain})$$

$$P_\infty(\text{rain}) = 1/3P_\infty(\text{sun})$$

$X_{t-1}$	$X_t$	$P(X_t X_{t-1})$
sun	sun	0.9
sun	rain	0.1
rain	sun	0.3
rain	rain	0.7

Επίσης:  $P_\infty(\text{sun}) + P_\infty(\text{rain}) = 1 \Rightarrow P_\infty(\text{sun}) = 3/4$   
 $P_\infty(\text{rain}) = 1/4$

# Κανόνας Bayes


- Δύο τρόποι για τον προσδιορισμό μιας κοινής κατανομής σε δύο εξαρτώμενες μεταβλητές:

$$P(x, y) = P(x|y)P(y) = P(y|x)P(x)$$

- Διαχωρίζοντας, παίρνουμε:

$$P(x|y) = \frac{P(y|x)P(x)}{P(y)}$$

- Γιατί είναι αυτό χρήσιμο;
  - Μας επιτρέπει να χτίσουμε μια πιθανότητα από την αντίστροφή της
  - Συχνά μια υπό συνθήκες κατανομή είναι δύσκολη αλλά η αντίστροφή της είναι απλή



# Δίκτυα Bayes - Bayes' Nets

Δύο προβλήματα υπάρχουν με τη χρήση πινάκων πλήρως διασυνδεδεμένης κατανομής ως πιθανοτικά μοντέλα:

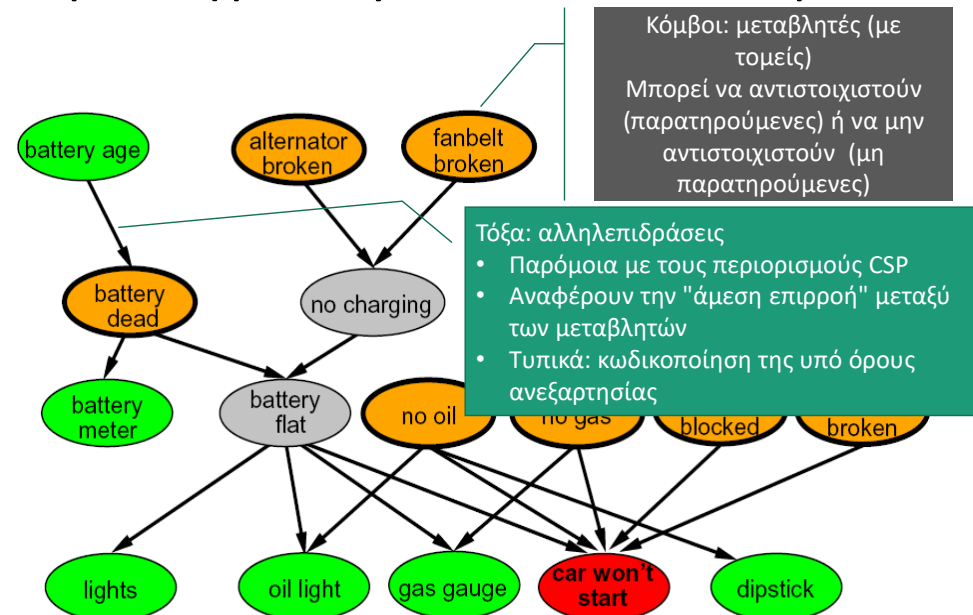
- Η διάρθρωση είναι πολύ μεγάλη ώστε να εκπροσωπείται ρητά, εκτός και αν υπάρχουν λίγες μεταβλητές
- Είναι δύσκολο να μάθεις (εκτιμήσεις) οτιδήποτε εμπειρικά για περισσότερες από μερικές μεταβλητές τη φορά

# Δίκτυα Bayes - Bayes' Nets

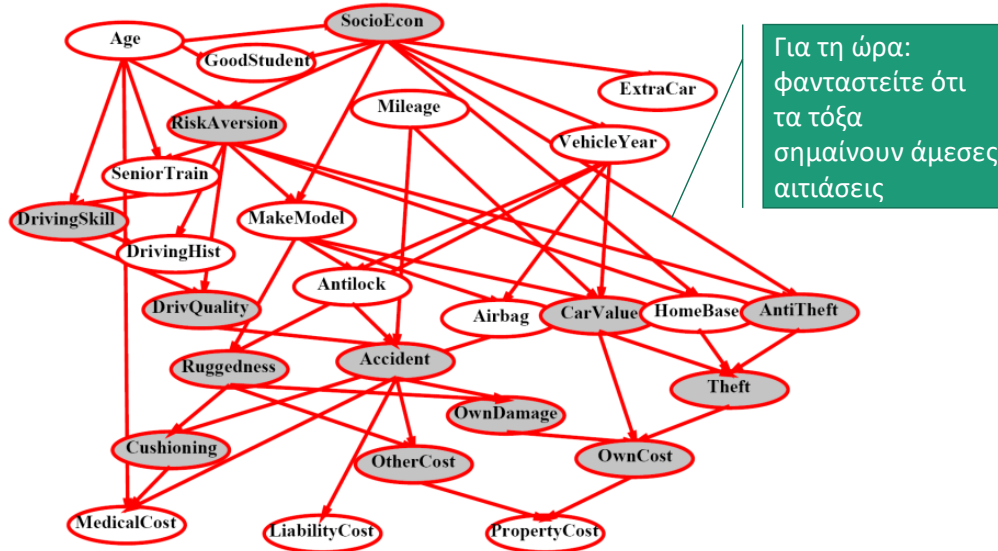
**Bayes' nets:** μια τεχνική για την περιγραφή πολύπλοκων κοινών κατανομών (μοντέλων) χρησιμοποιώντας απλές, τοπικές κατανομές (πιθανότητες υπό προϋποθέσεις - conditional probabilities)

- Πιο σωστά ονομάζονται γραφικά μοντέλα (**graphical models**)
- Περιγράφουν πώς αλληλεπιδρούν τοπικά οι μεταβλητές
- Τοπική αλυσίδα αλληλεπιδράσεων μαζί για να δώσει σφαιρικές, έμμεσες αλληλεπιδράσεις

# Παράδειγμα Bayes' Net: Αυτοκίνητο



## Παράδειγμα Bayes' Net: Ασφάλεια



## Παράδειγμα: Ρίξεις Νομίσματος

- N ανεξάρτητες ρίψεις νομίσματος



- Όχι συσχετισμοί μεταξύ των μεταβλητών: **απόλυτη ανεξαρτησία**


## Παράδειγμα: Κυκλοφοριακή συμφόρηση

- Variables:
  - R: It rains
  - T: There is traffic

■ Μοντέλο 1: ανεξαρτησία



■ Μοντέλο 2: εξάρτηση-η βροχή προκαλεί συμφόρηση



## Άσκηση: Κυκλοφοριακή συμφόρηση II

Φτιάξτε ένα γραφικό μοντέλο για την αλληλεξάρτηση των μεταβλητών:

- T: Συμφόρηση
- R: Βρέχει
- V: Ορατότητα
- A: Ατύχημα
- S: Οδόστρωμα
- C: Κλειστοί δρόμοι






# Τα Semantics των Bayes' Δικτύων

- Ένα σύνολο κόμβων, ένας για κάθε μεταβλητή  $X$
- Ένας κατευθυνόμενος, άκυκλος γράφος (που συνθέτουν οι ακμές)
- Μια κατανομή υπό συνθήκη για κάθε κόμβο
  - Μια συλλογή από κατανομές επί του  $X$ ,  

$$P(X|a_1 \dots a_n)$$
  - Ένας CPT: πίνακας υπό συνθήκη πιθανότητας (conditional probability table)
  - Περιγραφή μιας θορυβώδους (noisy) «αιτιώδους» διαδικασίας




*A Bayes net = Topology (graph) + Local Conditional Probabilities*

## Πιθανότητες στα BNs

### Παράδειγμα 2

$$P(j \wedge m \wedge a \wedge \neg b \wedge \neg e) = P(j/a) P(m/a) P(a/\neg b, \neg e) P(\neg b) P(\neg e)$$



## Πιθανότητες στα BNs


- Τα Bayes' nets **κωδικοποιούν εμμέσως τις κοινές κατανομές**
  - Ως αποτέλεσμα των τοπικών υπό συνθήκες κατανομών

$$P(x_1, x_2, \dots, x_n) = \prod_{i=1}^n P(x_i | \text{parents}(X_i))$$

- Για να βρεθεί η πιθανότητα που δίνει ένα BN με πλήρη ανάθεση τιμών στους κόμβους του, αρκεί να πολλαπλασιαστούν μαζί όλες οι σχετικές συνθήκες :

- Παράδειγμα:

$$P(+cavity, +catch, -toothache)$$



## Πιθανότητες σε BNs

- Ο αλυσιδωτός κανόνας (ισχύει για όλες τις κατανομές):

$$P(x_1, x_2, \dots, x_n) = \prod_{i=1}^n P(x_i | x_1 \dots x_{i-1})$$

- Υποθέτουμε τις υπό συνθήκες ανεξαρτησίες :


$$P(x_i | x_1, \dots, x_{i-1}) = P(x_i | \text{parents}(X_i))$$

→ Μπορούμε να συμπεράνουμε ότι:

$$P(x_1, x_2, \dots, x_n) = \prod_{i=1}^n P(x_i | \text{parents}(X_i))$$

- Δεν είναι δυνατόν κάθε BN να μπορεί να αναπαραστήσει κάθε κοινή κατανομή
  - Η τοπολογία επιβάλλει κάποιες υπό συνθήκες ανεξαρτησίες


## Παράδειγμα: Ρίψεις Νομίσματος



$$P(h, h, t, h) =$$

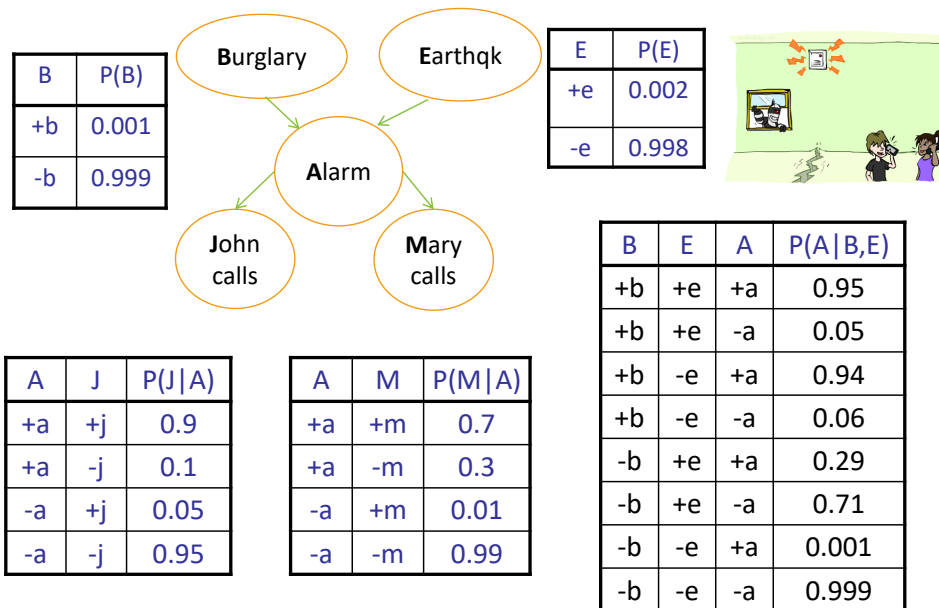
Μόνο κατανομές με ανεξάρτητες μεταβλητές μπορούν να αναπαρασταθούν με Bayes' net χωρίς τόξα.

## Παράδειγμα: Κυκλοφοριακή συμφόρηση

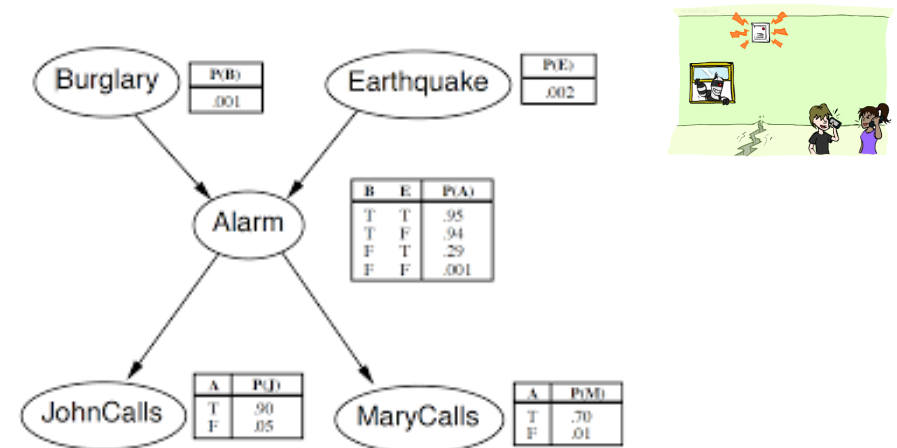


$$P(+r, -t) =$$

## Παράδειγμα: Συναγερμός



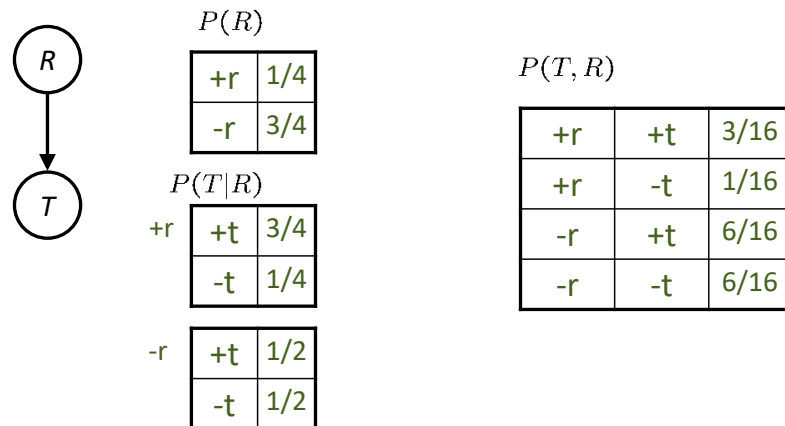
## Παράδειγμα: Συναγερμός (άλλη αναπαράσταση)





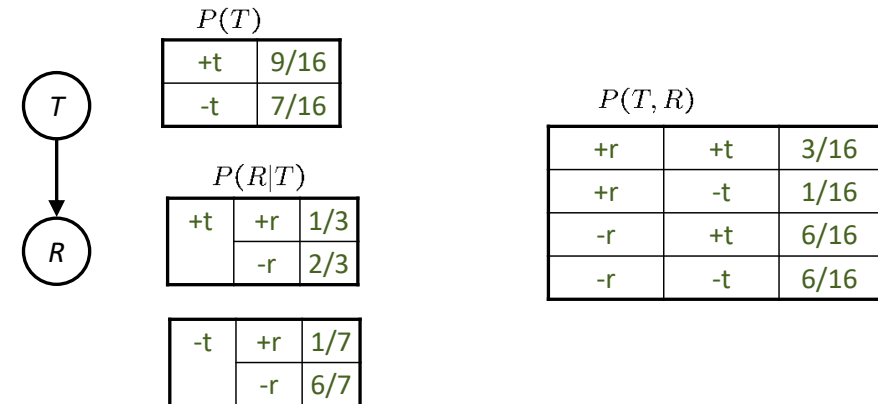
## Παράδειγμα: Κυκλοφοριακή συμφόρηση

- Αιτιώδης κατεύθυνση (Causal direction)



## Παράδειγμα: Αντίστροφη Κυκλοφοριακή Συμφόρηση

- Τι θα γίνει αν αντιστρέψουμε την αιτιώδη κατεύθυνση?



## Αλυσίδες Αιτίου-Αιτιατού

- Το παρακάτω αποτελεί μια “αιτιώδη αλυσίδα (causal chain)”
- Δυο απομακρυσμένες μεταβλητές της αλυσίδας ΔΕΝ ΕΙΝΑΙ απαραίτητα ανεξάρτητες.



- Για παράδειγμα:


$$P(+y \mid +x) = 1, P(-y \mid -x) = 1,$$

$$P(+z \mid +y) = 1, P(-z \mid -y) = 1$$

$$P(x, y, z) = P(x)P(y|x)P(z|y)$$

## Αλυσίδες Αιτίου-Αιτιατού

- Το παρακάτω αποτελεί μια “αιτιώδη αλυσίδα (causal chain)”
- Δυο απομακρυσμένες μεταβλητές της αλυσίδας ΕΙΝΑΙ ανεξάρτητες δεδομένων των ενδιάμεσων μεταβλητών.



- Για παράδειγμα:

$$P(z|x, y) = \frac{P(x, y, z)}{P(x, y)}$$

$$P(x, y, z) = P(x)P(y|x)P(z|y) = \frac{P(x)P(y|x)P(z|y)}{P(x)P(y|x)}$$

$$= P(z|y)$$

# Κατασκευή Bayesian δικτύων

$n$

$n$

1. Επέλεξε ένα σύνολο μεταβλητών  $X_1, \dots, X_n$
2. Από  $i = 1$  έως  $n$ 
  - πρόσθεσε  $X_i$  στο δίκτυο
  - Διάλεξε τους γονείς από το σύνολο  $X_1, \dots, X_{i-1}$  τέτοιους που
$$P(X_i | \text{Parents}(X_i)) = P(X_i | X_1, \dots, X_{i-1})$$


Μια τέτοια επιλογή γονέων εγγυάται ότι:

$$P(X_1, \dots, X_n) = \prod_{i=1}^n P(X_i | X_1, \dots, X_{i-1}) \text{ (chain rule)}$$

$$= \prod_{i=1}^n P(X_i | \text{Parents}(X_i)) \text{ (εκ της κατασκευής)}$$

# Παράδειγμα κατασκευής BN

Έστω ότι επιλέγουμε τη σειρά των μεταβλητών  $M, J, A, B, E$  για το παράδειγμα του συναγερμού




Ισχύει ότι

$$P(J | M) = P(J)?$$

# Παράδειγμα κατασκευής BN

Έστω ότι επιλέγουμε τη σειρά των μεταβλητών  $M, J, A, B, E$  για το παράδειγμα του συναγερμού




Ισχύει ότι

$$P(J | M) = P(J)? \text{ No}$$

$$P(A | J, M) = P(A | J)? \quad P(A | J, M) = P(A)?$$

# Παράδειγμα κατασκευής BN

Έστω ότι επιλέγουμε τη σειρά των μεταβλητών  $M, J, A, B, E$  για το παράδειγμα του συναγερμού



Ισχύει ότι

$$P(J | M) = P(J)? \text{ No}$$


$$P(A | J, M) = P(A | J)? \quad P(A | J, M) = P(A)? \text{ No}$$

$$P(B | A, J, M) = P(B | A)?$$

$$P(B | A, J, M) = P(B)?$$

## Παράδειγμα κατασκευής BN

Έστω ότι επιλέγουμε τη σειρά των μεταβλητών  
M, J, A, B, E για το παράδειγμα του συναγερμού



Ισχύει ότι

$$P(J \mid M) = P(J)? \text{ No}$$

$$P(A \mid J, M) = P(A \mid J)? \quad P(A \mid J, M) = P(A)? \text{ No}$$

$$P(B \mid A, J, M) = P(B \mid A)? \text{ Yes}$$


$$P(B \mid A, J, M) = P(B)? \text{ No}$$

$$P(E \mid B, A, J, M) = P(E \mid A)?$$

$$P(E \mid B, A, J, M) = P(E \mid A, B)?$$

## Παράδειγμα κατασκευής BN

Έστω ότι επιλέγουμε τη σειρά των μεταβλητών  
M, J, A, B, E για το παράδειγμα του συναγερμού



Ισχύει ότι

$$P(J \mid M) = P(J)? \text{ No}$$

$$P(A \mid J, M) = P(A \mid J)? \quad P(A \mid J, M) = P(A)? \text{ No}$$

$$P(B \mid A, J, M) = P(B \mid A)? \text{ Yes}$$

$$P(B \mid A, J, M) = P(B)? \text{ No}$$

$$P(E \mid B, A, J, M) = P(E \mid A)? \text{ No}$$

$$P(E \mid B, A, J, M) = P(E \mid A, B)? \text{ Yes}$$

## Άσκηση: Συναγερμός

Φτιάξτε BN για την αλληλεξάρτηση των παρακάτω μεταβλητών και τους αντίστοιχους πίνακες πιθανοτήτων και αλληλεξαρτήσεων και αναφέρετε ρητά τις αλυσίδες αιτίου-αιτιατού και τις ανεξάρτητες μεταξύ τους μεταβλητές :

C: Εκδήλωση καρκίνου

A: Ηλικία

G: Φύλλο

E: Έκθεση σε τοξικά

S: Κάπνισμα

L: Καρκίνος του πνεύμονα

T: Χημειοθεραπεία

## Δίκτυα Απόφασης

- Επιλογή ενέργειας που μεγιστοποιεί την προσδοκώμενη ωφέλεια (u) βάσει των ισχυρισμών

- Νέοι τύποι κόμβων:



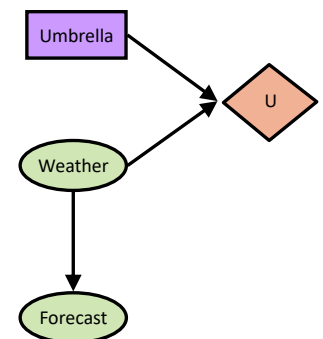
- Κόμβοι πιθανότητας (ακριβώς όπως στα BNs)



- Ενέργειες (ορθογώνια, δεν μπορούν να έχουν γονείς, ενεργούν ως παρατηρούμενα στοιχεία)




- Κόμβος χρησιμότητας (ρόμβος, εξαρτάται από κόμβους δράσης και πιθανότητας)



# Δίκτυα Απόφασης

## Επιλογή Ενέργειας

- Υποθέστε όλους τους ισχυρισμούς για το πρόβλημα (καιρός)
- Θέστε τους κόμβους ενεργειών με κάθε αρμόζοντα τρόπο (να πάρω-να μη πάρω ομπρέλα)
- Υπολογίστε τα προγενέστερα για όλους τους γονείς του κόμβου χρησιμότητας, δεδομένων των ισχυρισμών που υποθέσατε (πρόγνωση)
- Υπολογίστε την αναμενόμενη χρησιμότητα για κάθε κόμβο ενέργειας
- Επιλέξτε την ενέργεια που μεγιστοποιεί το αποτέλεσμα



# Δίκτυα Απόφασης

**Umbrella = leave**


$$EU(\text{leave}) = \sum_w P(w)U(\text{leave}, w) \\ = 0.7 \cdot 100 + 0.3 \cdot 0 = 70$$

**Umbrella = take**

$$EU(\text{take}) = \sum_w P(w)U(\text{take}, w) \\ = 0.7 \cdot 20 + 0.3 \cdot 70 = 35$$

**Optimal decision = leave**

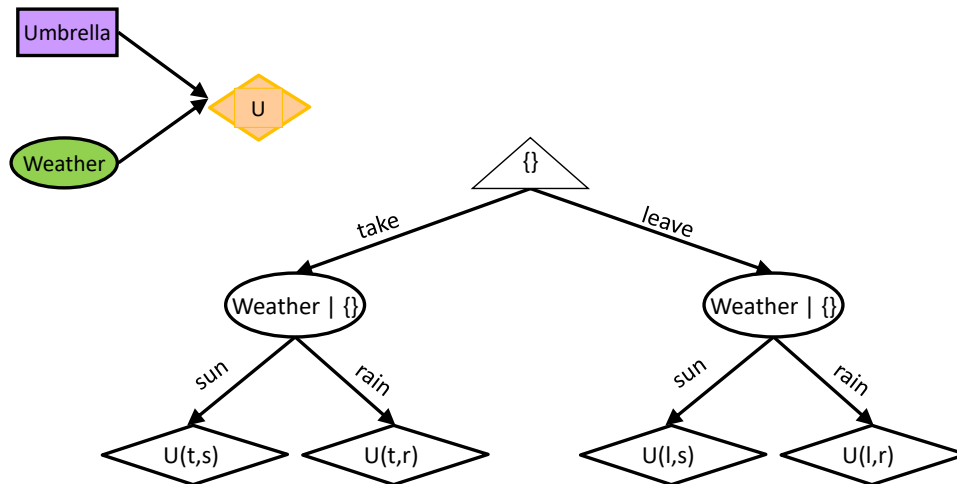
$$MEU(\emptyset) = \max_a EU(a) = 70$$



W	P(W)
sun	0.7
rain	0.3

A	W	U(A,W)
leave	sun	100
leave	rain	0
take	sun	20
take	rain	70

## Οι Αποφάσεις ως Δένδρα



## Παράδειγμα: Δίκτυα Απόφασης

**Umbrella = leave**

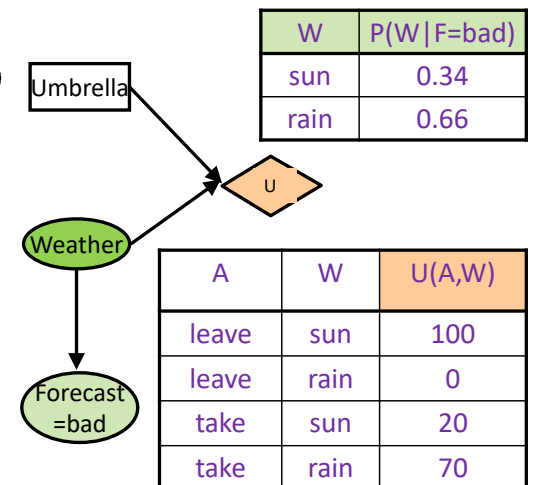
$$EU(\text{leave}|\text{bad}) = \sum_w P(w|\text{bad})U(\text{leave}, w) \\ = 0.34 \cdot 100 + 0.66 \cdot 0 = 34$$

**Umbrella = take**

$$EU(\text{take}|\text{bad}) = \sum_w P(w|\text{bad})U(\text{take}, w) \\ = 0.34 \cdot 20 + 0.66 \cdot 70 = 53$$

**Optimal decision = take**


$$MEU(F = \text{bad}) = \max_a EU(a|\text{bad}) = 53$$



W	P(W F=bad)
sun	0.34
rain	0.66

A	W	U(A,W)
leave	sun	100
leave	rain	0
take	sun	20
take	rain	70

# Αποφάσεις ως Δένδρα



Τέλος Ενότητας